IA024 - Respostas

February 14, 2024

1 Respostas das Questões do Processo Seletivo Aluno Especial IA-024 1S2024 FEEC-UNICAMP

1.1 Aluno: Fabio Grassiotto

1.2 RA: 890441

Link para o notebook com a implementação:
https://colab.research.google.com/drive/1xtikSpHPHJylcKZA_XAXJv9mSlV0cLS9?usp=sharing

Seção I

I.1. Na célula de calcular o vocabulário, aproveite o laço sobre IMDB de treinamento e utilize um segundo contador para calcular o número de amostras positivas e amostras negativas. Calcule também o comprimento médio do texto em número de palavras dos textos das amostras. Código implementado na seção I do notebook. Seguem os resultados obtidos:

Amostras positivas, negativas e totais: Counter({'total': 25000, 'pos': 12500, 'neg': 12500})

Comprimento médio do texto em palavras 270.68748

I.2 Mostre as cinco palavras mais frequentes do vocabulário e as cinco palavras menos frequentes. (Utilizando o Tokenizador)

Cinco palavras mais frequentes: ['the', '.', ',', 'and', 'a']

Cinco palavras menos frequentes: ['voicing', 'hazard', 'lynda', 'gft', 'watergate']

Qual é o código do token que está sendo utilizado quando a palavra não está no vocabulário? Na função de dicionário dict.get() o segundo parâmetro indica o valor default caso a palavra não seja encontrada no dicionário. Nesse caso o código do token usado é o número zero.

Número de tokens que não estão no vocabulário na base de treinamento: 174226

I.3.a) Qual é a razão pela qual o modelo preditivo conseguiu acertar 100% das amostras de teste do dataset selecionado com apenas as primeiras 200 amostras? Ao reduzirmos a base de treinamento para apenas 200 amostras, a base se tornou totalmente desbalanceada. Como pudemos verificar, temos 200 amostras classificadas como negativas e nenhuma como positiva.

Portanto a taxa de acurácia calculada sobre a classificação da base de testes depende unicamente da percentagem de amostras positivas ou negativas nesta base.

I.3.b) Modifique a forma de selecionar 200 amostras do dataset, porém garantindo que ele continue balanceado, isto é, aproximadamente 100 amostras positivas e 100 amostras negativas. Para obtermos um dataset balanceado, usaremos uma função que seleciona amostras do dataset de acordo com a classificação e cria um dataset com a quantidade de amostras de cada classificação desejada conforme abaixo.

Seção II

II.1.a) Investigue o dataset criado na linha 24. Faça um código que aplique um laço sobre o dataset train_data e calcule novamente quantas amostras positivas e negativas do dataset. Seção do código implementado:

```
counter_lbl = Counter({"pos": 0, "neg": 0, "total": 0})
words_encoded = 0
for (oneHot, sentiment) in train_data:

    words = oneHot.tolist()
    label = sentiment.item()

    # Número de amostras positivas e negativas
    if (label == 1):
      counter_lbl['neg'] += 1
    else:
      counter_lbl['pos'] += 1
    counter_lbl['total'] += 1

    hot_encoded = sum(words[i] for i in range(len(words)) if words[i] != 0)
    words_encoded +=  hot_encoded

avg_words_enc = words_encoded / counter_lbl['total']
```

II.1.b) Calcule também o número médio de palavras codificadas em cada vetor one-hot. Quantidade média de palavras codificadas em cada vetor one-hot 139.59268

Compare este valor com o comprimento médio de cada texto (contado em palavras), conforme calculado no exercício I.1.c. e explique a diferença. No exercício I.1.c, o comprimento médio do texto em palavras depois de passar pelo tokenizador foi de cerca de 270 palavras. Essa diferença do vetor One-Hot se deve ao fato que o vetor one-hot só codifica as palavras que foram identificadas no dicionário, enquanto que o comprimento médio considera todas as palavras das sentenças. Ou seja, palavras que não foram codificadas no dicionário serão representadas por zeros.

II.2.a) Medição dos tempos de loop Notamos que o tempo do passo do forward leva mais tempo que o passo de backward, conforme os dados obtidos abaixo para a primeira época do

treinamento. Também notamos que a maior parte to tempo do loop de forward é gasto com a transferência dos dados da CPU para a GPU (97% no primeiro loop).

```
Loop # 1
Tempo de loop =  0.048320770263671875
Forward pass =  0.047322750091552734
Gpu copy = 97.88851606662435 %
Model processing = 2.1114839333756574 %
Backward pass =  0.0009980201721191406

Loop # 2
Tempo de loop =  0.007141590118408203
Forward pass =  0.005140781402587891
Gpu copy = 80.50737408403673 %
Model processing = 19.49262591596327 %
Backward pass =  0.0020008087158203125
```

II.2.b) Trecho que precisa ser otimizado. (Esse é um problema mais difícil) Para otimizarmos o loop, o carregamento dos dados em GPU pode ser realizado pelo Dataloader fora do loop de treinamento, para tanto alterando o método **init**() da classe IMDBDataset.

```
def __init__(self, split, vocab):
    #self.data = list(IMDB(split=split))[:n_samples]
    self.data = list(balanced_dataset(IMDB(split=split), n_samples))
    self.vocab = vocab
```

II.2.c) Otimize o código e explique aqui. Substituimos então com a nova implementação, onde o dataset inteiro é pré-processado, codificado em forma One-Hot (uma vez que tensores não suportam strings) e movido para a GPU antes do processo de treinamento:

```
def __init__(self, split, vocab):

    # II.2.b) Trecho que precisa ser otimizado. (Esse é um problema mais difícil)
    self.data = list(balanced_dataset(IMDB(split='train'), n_samples))

    if preload_to_gpu:
        labels = [x[0] for x in self.data]
        lines = [x[1] for x in self.data]

        # One-Hot Encoding
        self.labels_enc = []
        for l in labels:
        l = 1 if l == 1 else 0
        self.labels_enc.append(l)
        self.labels_enc = torch.tensor(self.labels_enc)
        self.labels_enc = self.labels_enc.to(device)

        self.lines_enc = []
        for l in lines:
```

```
            X = torch.zeros(len(vocab) + 1)
            for word in encode_sentence(l, vocab):
                X[word] = 1
            self.lines_enc.append(X)
            self.lines_enc = [tensor.to(device) for tensor in self.lines_enc]

        self.vocab = vocab
```

Comparação do tempo de treinamento com a otimização (GPU RTX2060 local): Sem pre-load em GPU:

```
Epoch [1/5],            Loss: 0.6911,            Elapsed Time: 61.36 sec
Epoch [2/5],            Loss: 0.6929,            Elapsed Time: 58.69 sec
Epoch [3/5],            Loss: 0.6984,            Elapsed Time: 58.95 sec
Epoch [4/5],            Loss: 0.6792,            Elapsed Time: 58.60 sec
Epoch [5/5],            Loss: 0.6874,            Elapsed Time: 58.59 sec
```

Com pre-load em GPU (RTX2060)

```
Epoch [1/5],            Loss: 0.6896,            Elapsed Time: 3.81 sec
Epoch [2/5],            Loss: 0.6925,            Elapsed Time: 0.58 sec
Epoch [3/5],            Loss: 0.6933,            Elapsed Time: 0.64 sec
Epoch [4/5],            Loss: 0.6890,            Elapsed Time: 0.58 sec
Epoch [5/5],            Loss: 0.6904,            Elapsed Time: 0.57 sec
```

Notamos, no entanto, que o uso de mémória na GPU se torna muito maior, conforme pode ser visualizado abaixo (5Gb/6Gb total):

```
[venv:ml] $ nvidia-smi
Mon Feb 12 08:23:42 2024
+-----------------------------------------------------------------------------+
| NVIDIA-SMI 516.94       Driver Version: 516.94       CUDA Version: 11.7     |
|-------------------------------+----------------------+----------------------+
| GPU  Name            TCC/WDDM | Bus-Id        Disp.A | Volatile Uncorr. ECC |
| Fan  Temp  Perf  Pwr:Usage/Cap|         Memory-Usage | GPU-Util  Compute M. |
|                               |                      |               MIG M. |
|===============================+======================+======================|
|   0  NVIDIA GeForce ... WDDM  | 00000000:01:00.0  On |                  N/A |
| N/A   76C    P8    12W /  N/A |   5035MiB /  6144MiB |      1%      Default |
|                               |                      |                  N/A |
+-------------------------------+----------------------+----------------------+
```

II.3 Faça a melhor escolha do LR, analisando o valor da acurácia no conjunto de teste, utilizando para cada valor de LR, a acurácia obtida. Faça um gráfico de Acurácia vs LR e escolha o LR que forneça a maior acurácia possível.

[14]:
```
lr_list = [0.0001, 0.001, 0.01, 0.1]
acc_list = []

for lr in lr_list:
```

```
    print("LR = ", lr)
    model = OneHotMLP(vocab_size) # to reset weights
    train_mdl(model, lr)
    acc_list.append(eval_mdl(model))
    print()

print(lr_list)
print(acc_list)
print()
```

```
LR =  0.0001
Epoch [1/5],              Loss: 0.6939,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5000
Epoch [2/5],              Loss: 0.6937,              Elapsed Time: 0.46 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5003
Epoch [3/5],              Loss: 0.6941,              Elapsed Time: 0.47 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5002
Epoch [4/5],              Loss: 0.6942,              Elapsed Time: 0.49 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5003
Epoch [5/5],              Loss: 0.6954,              Elapsed Time: 0.51 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5002
Test Accuracy: 52.412%

LR =  0.001
Epoch [1/5],              Loss: 0.6956,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.4998
Epoch [2/5],              Loss: 0.6914,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5000
Epoch [3/5],              Loss: 0.6853,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5003
Epoch [4/5],              Loss: 0.6860,              Elapsed Time: 0.36 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.4999
Epoch [5/5],              Loss: 0.7005,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.4990
Test Accuracy: 54.152%

LR =  0.01
```

```
Epoch [1/5],              Loss: 0.6765,              Elapsed Time: 0.36 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5000
Epoch [2/5],              Loss: 0.6476,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.4998
Epoch [3/5],              Loss: 0.5837,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5001
Epoch [4/5],              Loss: 0.4483,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5000
Epoch [5/5],              Loss: 0.5591,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5001
Test Accuracy: 82.02%

LR =  0.1
Epoch [1/5],              Loss: 0.3548,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5001
Epoch [2/5],              Loss: 0.2222,              Elapsed Time: 0.36 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5007
Epoch [3/5],              Loss: 0.2340,              Elapsed Time: 0.36 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5002
Epoch [4/5],              Loss: 0.3581,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5002
Epoch [5/5],              Loss: 0.3277,              Elapsed Time: 0.37 sec,
Loader Iterations: 196,             Spls lst batch: 40 ,              R avg:
0.5004
Test Accuracy: 88.212%

[0.0001, 0.001, 0.01, 0.1]
[52.412, 54.152, 82.02, 88.212]
```

II.3.a) Gráfico Acurácia vs LR

[15]:
```python
import seaborn as sns
import matplotlib.pyplot as plt

sns.set_style("darkgrid")
sns.lineplot(x=lr_list, y=acc_list)

# Add labels and title
```

```
plt.xlabel("Learning Rate")
plt.ylabel("Accuracy")
plt.title("Accuracy vs Learning Rate")

# Show the plot
plt.show()
```

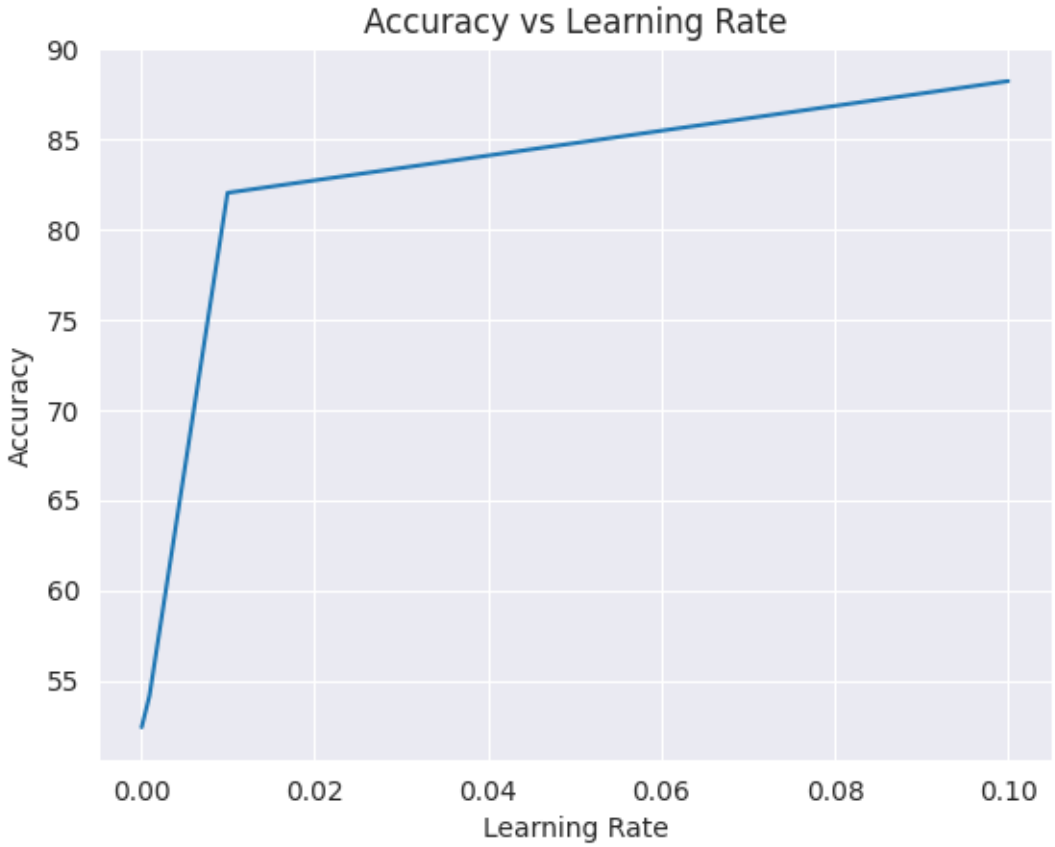

II.3.b) Valor ótimo do LR Notamos que o valor ótimo para a Learning Rate foi de cerca de 0.1, com crescimento exponencial ao aumentá-la. Valores acima deste são grandes demais e não levam à otimização do modelo.

II.3.c) Mostre a equação utilizada no gradiente descendente e qual é o papel do LR no ajuste dos parâmetros (weights) do modelo da rede neural. No processo de otimização de uma função, a fórmula utilizada para a estimativa do próximo valor da função é dada por:

`valor atualizado = valor anterior - learning rate*gradiente`

Portanto o papel da LR é definir qual é o *tamanho* do passo a ser utilizado no processo de atualização.

II.4 Melhores a forma de tokenizar, isto é, pré-processar o dataset de modo que a codificação seja indiferente das palavras serem escritas com maiúsculas ou minúsculas e sejam pouco influenciadas pelas pontuações.

II.4.a) Mostre os trechos modificados para este novo tokenizador, tanto na seção I - Vocabulário, como na seção II - Dataset. Na seção I - Vocabulário:

```
from torchtext.data import get_tokenizer

for (label, line) in list(IMDB(split='train'))[:n_samples]:
    if (use_tokenizer):
      tokenizer = get_tokenizer('basic_english')
      # tokenize the sentence
      line = tokenizer(line)
    counter.update(line.split())

    # Número de amostras positivas e negativas
    if (label == 1):
      counter_lbl['neg'] += 1
    else:
      counter_lbl['pos'] += 1
    counter_lbl['total'] += 1

    # Comprimento médio do texto das reviews em palavras
    tokenizer = get_tokenizer('basic_english')

    # tokenize the sentence
    tokens = tokenizer(line)

    # count the number of words
    total_review_len += len(tokens)
```

Na Seção II - Dataset: São apenas necessárias alterações no encoder da sentença, conforme abaixo.

```
def encode_sentence(sentence, vocab, use_tokenizer):
    if (use_tokenizer):
       sentence = tokenizer(sentence)
       return [vocab.get(word, 0) for word in sentence]
    else:
      return [vocab.get(word, 0) for word in sentence.split()] # 0 for OOV
```

II.4.b) Recalcule novamente os valores do exercício I.2.c - número de tokens unknown, e apresente uma tabela comparando os novos valores com os valores obtidos com o tokenizador original e justifique os resultados obtidos. Sem o tokenizador:

566141

Com o tokenizador:

174226

Estes valores se justificam pelo fato que o tokenizador altera as palavras das sentenças, mantendo apenas radicais, de forma que menos palavras não serão encontradas na base do vocabulário.

II.4.c) Execute agora no notebook inteiro com o novo tokenizador e veja o novo valor da acurácia obtido com a melhoria do tokenizador. Sem o tokenizador:

Test Accuracy: 73.45% (Para LR = 0.1)

Com o tokenizador

Test Accuracy: 88.47% (Para LR = 0.1)

O aumento da acurácia é justificado pelo fato que menos palavras de cada sentença não serão reconhecidas (OneHot encoding não terá tantos valores zerados)

Os dados obtidos estão resumidos na tabela abaixo.

[16]:
```
from tabulate import tabulate

# Sample data
data = [
    ['Sem Tokenizador', 566141, '73.45%'],
    ['Com Tokenizador', 174226, '88.47%'],
]

# Headers
headers = ['Uso do Tokenizador', 'Tokens Unknown', 'Test Accuracy']

# Print the table
print(tabulate(data, headers=headers))
```

```
Uso do Tokenizador      Tokens Unknown  Test Accuracy
--------------------  ----------------  ---------------
Sem Tokenizador                 566141  73.45%
Com Tokenizador                 174226  88.47%
```

Seção III

Vamos estudar agora o Data Loader da seção III do notebook. Em primeiro lugar anote a acurácia do notebook com as melhorias de eficiência de rodar em GPU, com ajustes de LR e do tokenizador. Em seguida mude o parâmetro shuffle na construção do objeto train_loader para False e execute novamente o notebook por completo e meça novamente a acurácia.

[17]:
```
from tabulate import tabulate

# Sample data
data = [
    ['Com Shuffle', '88.47%'],
    ['Sem Shuffle', '50.00%']
]
```

```
# Headers
headers = ['Shuffle dos dados de Treinamento', 'Test Accuracy']

# Print the table
print(tabulate(data, headers=headers))
```

```
Shuffle dos dados de Treinamento    Test Accuracy
----------------------------------  ---------------
Com Shuffle                         88.47%
Sem Shuffle                         50.00%
```

III.1.a) Explique as duas principais vantagens do uso de batch no treinamento de redes neurais. O uso de lotes em treinamento é importante por causa do aumento da eficiência computacional e para aumentar a estabilidade do gradiente. A eficiência computacional é aumentada pois com lotes maiores a paralelização do processamento em GPUs é mais bem aproveitada, enquanto que a estabilidade do gradiente é aumentada durante o treinamento pois em cada iteração, o gradiente é calculado com base na função de perda para o lote inteiro reduzindo a variabilidade do gradiente em comparação com o cálculo individual para cada exemplo.

III.1.b) Explique por que é importante fazer o embaralhamento das amostras do batch em cada nova época. O embarelhamento das amostras de batch do treinamento é essencial para aumentar a generabilidade do modelo. As razões para tanto são:

- Redução do viés das amostras ordenadas do início ao fim do dataset.
- Estabilização do gradiente (redução da oscilação causada por amostras ordenadas).
- Melhoria da convergência, pois amostras agrupadas de uma classe dificultam o processo de aprendizado da rede neural.

Em geral o embaralhamento de amostras de treinamento é um processo usual para a redução da generalização e a obtenção de um modelo de melhores características.

III.1.c) Se você alterar o shuffle=False no instanciamento do objeto test_loader, por que o cálculo da acurácia não se altera? A acurácia não se altera pois em tempo de inferência (ou seja, fase de teste) os pesos do modelo não são alterados mais. Portanto, a base de testes é usada apenas para verificar a capacidade de generalização do modelo.

III.2.a) Faça um laço no objeto train_loader e meça quantas iterações o Loader tem. Mostre o código para calcular essas iterações. Explique o valor encontrado. Modificações no código de treinamento (função train_mdl()) acima:

```
for epoch in range(num_epochs):
    start_time = time.time()  # Start time of the epoch
    model.train()

    loop_count = 0

    train_loader_iterations = 0
```

```
    for inputs, labels in train_loader:
        train_loader_iterations += 1
```

Número de interações por época:

```
Epoch [1/5],              Loss: 0.3918,              Elapsed Time: 6.79 sec,              Lo
Epoch [2/5],              Loss: 0.3028,              Elapsed Time: 0.56 sec,              Lo
Epoch [3/5],              Loss: 0.1997,              Elapsed Time: 0.57 sec,              Lo
Epoch [4/5],              Loss: 0.1883,              Elapsed Time: 0.57 sec,              Lo
Epoch [5/5],              Loss: 0.3806,              Elapsed Time: 0.56 sec,              Lo
```

III.2.b) Imprima o número de amostras do último batch do train_loader e justifique o valor encontrado? Ele pode ser menor que o batch_size?

```
Number of samples in last batch: 40
```

O valor encontrado é menor que o tamanho do batch size (nesse caso, 128) pois esta é a quantidade de amostras restantes nas base. Como temos 196 iterações, o total de amostras nos primeiros 195 ciclos totaliza 24.960. Portanto, o último batch tem um total de 25.000 (tamanho da base) - 24.960 = 40.

III.2.c) Calcule R, a relação do número de amostras positivas sobre o número de amostras no batch e no final encontre o valor médio de R, para ver se o data loader está entregando batches balanceados. Desta vez, em vez de fazer um laço explícito, utilize list comprehension para criar uma lista contendo a relação R de cada amostra no batch. No final, calcule a média dos elementos da lista para fornecer a resposta final. Médias de R por época:

```
R avg: 0.4999
R avg: 0.5004
R avg: 0.5003
R avg: 0.4999
R avg: 0.5000
```

III.2.d) Mostre a estrutura de um dos batches. Cada batch foi criado no método getitem do Dataset, linha 20. É formado por uma tupla com o primeiro elemento sendo a codificação one-hot do texto e o segundo elemento o label esperado, indicando positivo ou negativo. Mostre o shape (linhas e colunas) e o tipo de dado (float ou integer), tanto da entrada da rede como do label esperado. Desta vez selecione um elemento do batch do train_loader utilizando as funções next e iter: batch = next(iter(train_loader)).

[18]:
```python
my_loader = DataLoader(train_data, batch_size=1)
batch = next(iter(my_loader))

# Dado de entrada
entrada = batch[0].tolist()
dado_entrada = (batch[0])[0]

print("Dado de entrada:")
```

```
print(dado_entrada.size())
print(dado_entrada.dtype)
print()

# Label
print("Label:")
lbl = batch[1]
print(lbl.size())
print(lbl.dtype)
```

```
Dado de entrada:
torch.Size([20001])
torch.float32

Label:
torch.Size([1])
torch.int64
```

III.3.a) Verifique a influência do batch size na acurácia final do modelo. Experimente usar um batch size de 1 amostra apenas e outro com mais de 128 e comente sobre os resultados. Notei que o cálculo de perda da linha criterion() gera um erro com batch size = 1, então usei batch size = 2 para este exercício.

[19]:
```
# Acurácia com batch = 2
train_loader = DataLoader(train_data, batch_size=2, shuffle=train_shuffle)
model = OneHotMLP(vocab_size) # to reset weights
train_mdl(model, best_LR)
eval_mdl(model)
print()

# Acurácia com batch = 256
train_loader = DataLoader(train_data, batch_size=256, shuffle=train_shuffle)
model = OneHotMLP(vocab_size) # to reset weights
train_mdl(model, best_LR)
eval_mdl(model)
print()
```

```
Epoch [1/5],              Loss: 0.0217,              Elapsed Time: 17.09 sec,
Loader Iterations: 12500,             Spls lst batch: 2 ,              R avg:
0.5000
Epoch [2/5],              Loss: 0.5510,              Elapsed Time: 16.61 sec,
Loader Iterations: 12500,             Spls lst batch: 2 ,              R avg:
0.5000
Epoch [3/5],              Loss: 0.3738,              Elapsed Time: 16.82 sec,
Loader Iterations: 12500,             Spls lst batch: 2 ,              R avg:
0.5000
Epoch [4/5],              Loss: 0.0002,              Elapsed Time: 17.54 sec,
Loader Iterations: 12500,             Spls lst batch: 2 ,              R avg:
```

```
0.5000
Epoch [5/5],               Loss: 0.0039,               Elapsed Time: 17.01 sec,
Loader Iterations: 12500,              Spls lst batch: 2 ,               R avg:
0.5000
Test Accuracy: 86.568%

Epoch [1/5],               Loss: 0.4962,               Elapsed Time: 0.35 sec,
Loader Iterations: 98,               Spls lst batch: 168 ,               R avg:
0.4999
Epoch [2/5],               Loss: 0.4107,               Elapsed Time: 0.35 sec,
Loader Iterations: 98,               Spls lst batch: 168 ,               R avg:
0.5003
Epoch [3/5],               Loss: 0.3138,               Elapsed Time: 0.38 sec,
Loader Iterations: 98,               Spls lst batch: 168 ,               R avg:
0.5000
Epoch [4/5],               Loss: 0.3772,               Elapsed Time: 0.36 sec,
Loader Iterations: 98,               Spls lst batch: 168 ,               R avg:
0.4999
Epoch [5/5],               Loss: 0.2645,               Elapsed Time: 0.38 sec,
Loader Iterations: 98,               Spls lst batch: 168 ,               R avg:
0.5002
Test Accuracy: 87.728%
```

Pudemos verificar que o batch size muito reduzido aumenta em muito a acurácia, mas em contrapartida aumenta muito a complexidade computacional. O ganho da acurácia pode ser explicado pela melhoria na generalização. Nesse caso os pesos do modelo são atualizados depois da análise de cada amostra de forma independente. O aumento do batch size de 128 para 256 não trouxe ganhos na acurácia. Portanto, para datasets pequenos como o caso deste exercício, uma redução do tamanho do batch pode ser benéfico desde que o custo computacional não seja excessivo.

Seção IV

IV.1.a) Faça a predição do modelo utilizando um batch do train_loader: extraia um batch do train_loader, chame de (input, target), onde input é a entrada da rede e target é o label esperado. Como a rede está com seus parâmetros (weights) aleatórios, o logito de saída da rede será um valor aleatório, porém a chamada irá executar sem erros: logit = model(input)

aplique a função sigmoidal ao logito para convertê-lo numa probabilidade de valor entre 0 e 1.

[20]:
```
import numpy as np
new_loader = DataLoader(train_data, batch_size=128, shuffle=train_shuffle)
model = OneHotMLP(vocab_size).to(device)

input, target = next(iter(new_loader))
logit = model(input)
```

```
# Define the sigmoid function
def sigmoid(x):
  return 1 / (1 + torch.exp(-x))

probability = sigmoid(logit[0])*100

# Cálculo da probabilidade para a primeira amostra
print(f'Probabilidade: {probability.item():.2f} %')
```

```
Probabilidade: 47.73 %
```

IV.1.b) Agora, treine a rede executando o notebook todo e verifique se a acurácia está alta. Agora repita o exercício anterior, porém agora, compare o valor da probabilidade encontrada com o target esperado e verifique se ele acertou. Você pode considerar que se a probabilidade for maior que 0.5, pode-se dar o label 1 e se for menor que 0.5, o label 0. Observe isso que é feito na linha 11 da seção VI - Avaliação.

[21]:
```
import numpy as np
new_loader = DataLoader(train_data, batch_size=128, shuffle=train_shuffle)
model = OneHotMLP(vocab_size).to(device)

input, target = next(iter(new_loader))
logit = model(input).cpu()

predicted = torch.round(torch.sigmoid(logit.squeeze()))

print("Predição = ", predicted[0].item())
print("Target Esperado = ", target[0].item())
```

```
Predição =  0.0
Target Esperado =  1
```

Se você der um print no modelo: print(model), você obterá:

```
OneHotMLP(
  (fc1): Linear(in_features=20001, out_features=200, bias=True)
  (fc2): Linear(in_features=200, out_features=1, bias=True)
  (relu): ReLU()
)
```

Os pesos da primeira camada podem ser visualizados com model.fc1.weight e o elemento constante (bias) pode ser visualizado com model.fc1.bias
Calcule o número de parâmetros do modelo, preenchendo a seguinte tabela (utilize shape para verificar a estrutura de cada parâmetro do modelo).

[22]:
```
from tabulate import tabulate

model = OneHotMLP(vocab_size)
```

```
w_fc1 = model.fc1.weight.size()
b_fc1 = model.fc1.bias.size()
w_fc2 = model.fc2.weight.size()
b_fc2 = model.fc2.bias.size()

print("Model Parameters:")
print("FC1 weights dimensions: ", list(w_fc1))
print("FC2 weights dimensions: ", list (w_fc2))
print("FC1 bias dimensions: ", list(b_fc1))
print("FC2 bias dimensions: ", list (b_fc2))
print()

# Table data
data = [
    ['', 'weight', 'bias', 'weight', 'bias', ''],
    ['size', w_fc1[0]*w_fc1[1], b_fc1[0], w_fc2[0]*w_fc2[1], b_fc2[0], '']
]

# Headers
headers = ['layer', 'fc1', '', 'fc2', '', 'total']

# Print the table
print(tabulate(data, headers=headers))
```

```
Model Parameters:
FC1 weights dimensions:  [200, 20001]
FC2 weights dimensions:  [1, 200]
FC1 bias dimensions:  [200]
FC2 bias dimensions:  [1]

layer    fc1            fc2           total
-------  -------  ----  ------  ----  -------
         weight   bias  weight  bias
size     4000200  200   200     1
```

Seção V

V.1.a) Qual é o valor teórico da Loss quando o modelo não está treinado, mas apenas inicializado? Isto é, a probabilidade predita tanto para a classe 0 como para a classe 1, é sempre 0,5 ? Justifique. Atenção: na equação da Entropia Cruzada utilize o logaritmo natural. Utilizando a equação da entropia cruzada, podemos obter o valor teórico da perda:

Loss = -1/n SumN (yi * ln(y^i) + (1-yi)ln(1-y^i))

com y^i = 0.5, temos: ln(y^i) = ln(1-y^i) = ln(0.5) = -0.69314

Loss = -1/n SumN(yi * (-0.69314) + (1-yi) * (-0.69314)) Loss = -1/n SumN(-0.69314yi - 0.69314 + 0.69314yi)

cancelando ambos termos em yi ->

Loss = -1/n SumN(-0.69314) e portanto Loss = 0.69314 para o modelo inicializado independente do número de amostras N.

No entanto, para um modelo não inicializado, o valor da perda depende do valor dos pesos da rede neural não inicializada, que pode variar e não ser o mesmo que o valor teórico.

V.1.b) Utilize as amostras do primeiro batch: (input,target) = next(iter(train_loader)) e calcule o valor da Loss utilizando a equação fornecida anteriormente utilizando o pytorch. Verifique se este valor confere com o valor teórico do exercício anterior.

[23]:
```
new_loader = DataLoader(train_data, batch_size=128, shuffle=train_shuffle)
model = OneHotMLP(vocab_size).to(device)

input, target = next(iter(new_loader))
logit = model(input)
prob = torch.sigmoid(logit)

# Calculo numérico da perda
loss = - torch.sum(torch.mul(target, torch.log(prob).t()) + torch.mul(1-target,␣
 ↪torch.log(1-prob).t())) / prob.shape[0]
print(loss)
```

```
tensor(0.6917, device='cuda:0', grad_fn=<DivBackward0>)
```

Notamos que para um batch acima o valor da perda calculada não é a mesma da perda teórica, mas é muito próxima devido aos valores dos pesos não inicializados da rede neural.

V.1.c) O pytorch possui várias funções que facilitam o cálculo da Loss pela Entropia Cruzada. Utilize a classe nn.BCELoss (Binary Cross Entropy Loss). Você primeiro deve instanciar uma função da classe nn.BCELoss. Esta função instanciada recebe dois parâmetros (probs , targets) e retorna a Loss. Use a busca do Google para ver a documentação do BCELoss do pytorch. Calcule então a função de Loss da entropia cruzada, porém usando agora a função instanciada pelo BCELoss e confira se o resultado é exatamente o mesmo obtido no exercício anterior.

[24]:
```
loss_fn = nn.BCELoss()

loss = loss_fn(prob.squeeze(), target.float())
print(loss)
```

```
tensor(0.6917, device='cuda:0', grad_fn=<BinaryCrossEntropyBackward0>)
```

Notamos que o valor foi o mesmo que o obtido acima.

V.1.d) Repita o mesmo exercício, porém agora usando a classe nn.BCEWithLogitsLoss, que é a opção utilizada no notebook. O resultado da Loss deve igualar aos resultados anteriores.

[25]:
```
loss_fn = nn.BCEWithLogitsLoss()

loss = loss_fn(logit.squeeze(), target.float())
print(loss)
```

```
tensor(0.6917, device='cuda:0',
       grad_fn=<BinaryCrossEntropyWithLogitsBackward0>)
```

Novamente chegamos ao mesmo valor calculado.

V.2.a) Modifique a célula do laço de treinamento de modo que a primeira Loss a ser impressa seja a Loss com o modelo inicializado (isto é, sem nenhum treinamento), fornecendo a Loss esperada conforme os exercícios feitos anteriormente. Observe que desta forma, fica fácil verificar se o seu modelo está correto e a Loss está sendo calculada corretamente. Atenção: Mantenha esse código da impressão do valor da Loss inicial, antes do treinamento, nesta célula, pois ela é sempre útil para verificar se não tem nada errado, antes de começar o treinamento.

[26]:
```
# Medição da perda
def train_first_loss(model, lr):

  model = model.to(device)
  # Define loss and optimizer
  criterion = nn.BCEWithLogitsLoss()

  optimizer = optim.SGD(model.parameters(), lr)

  # Training loop
  num_epochs = 5
  # First loss calculation
  is_first_loss = True

  for epoch in range(num_epochs):
      start_time = time.time()
      model.train()

      for inputs, labels in train_loader:

          if not preload_to_gpu:
            inputs = inputs.to(device)
            labels = labels.to(device)

          # Forward pass
          outputs = model(inputs)
          loss = criterion(outputs.squeeze(), labels.float())

          if is_first_loss:
            print(f'Loss before training: {loss.item():.4f}')
```

```
            is_first_loss = False
            print()

          # Backward and optimize
          backward_start = time.time()
          optimizer.zero_grad()
          loss.backward()
          optimizer.step()

      print(f'Epoch [{epoch+1}/{num_epochs}], \
              Loss: {loss.item():.4f}')
  print()

model = OneHotMLP(vocab_size)
train_first_loss(model, best_LR)
```

```
Loss before training: 0.6928

Epoch [1/5],              Loss: 0.4690
Epoch [2/5],              Loss: 0.3171
Epoch [3/5],              Loss: 0.3201
Epoch [4/5],              Loss: 0.3079
Epoch [5/5],              Loss: 0.3412
```

Notamos que o primeiro valor calculado da perda se manteve o mesmo.

V.2.b) Execute a célula de treinamento por uma segunda vez e observe que a Loss continua diminuindo e o modelo está continuando a ser treinado. O que é necessário fazer para que o treinamento comece novamente do modelo aleatório? Qual(is) célula(s) é(são) preciso executar antes de executar o laço de treinamento novamente? Para que o treinamento inicie novamente, os pesos devem ser resetados a seus valores iniciais. Uma maneira de fazer isso é criando uma função que resete os parãmetros de cada camada, por exemplo:

[27]:
```
def reset_weights(model):
  for module in model.modules():
    if isinstance(module, nn.Linear):
      module.reset_parameters()
```

E adicionar ao loop de treinamento acima.

[28]:
```
# Medição da perda
def train_first_loss_reset(model, lr):

  model = model.to(device)
  reset_weights(model)
  # Define loss and optimizer
  criterion = nn.BCEWithLogitsLoss()
```

```
optimizer = optim.SGD(model.parameters(), lr)

# Training loop
num_epochs = 5
# First loss calculation
is_first_loss = True

for epoch in range(num_epochs):
    start_time = time.time()
    model.train()

    for inputs, labels in train_loader:

        if not preload_to_gpu:
          inputs = inputs.to(device)
          labels = labels.to(device)

        # Forward pass
        outputs = model(inputs)
        loss = criterion(outputs.squeeze(), labels.float())

        if is_first_loss:
          print(f'Loss before training: {loss.item():.4f}')
          is_first_loss = False
          print()

        # Backward and optimize
        backward_start = time.time()
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()

    print(f'Epoch [{epoch+1}/{num_epochs}], \
            Loss: {loss.item():.4f}')
print()
```

Sem o reset de parâmetros:

[29]:
```
model = OneHotMLP(vocab_size)
train_first_loss(model, best_LR)
train_first_loss(model, best_LR)
```

```
Loss before training: 0.6927

Epoch [1/5],              Loss: 0.4922
Epoch [2/5],              Loss: 0.3288
Epoch [3/5],              Loss: 0.3500
```

```
Epoch [4/5],                Loss: 0.2923
Epoch [5/5],                Loss: 0.3409

Loss before training: 0.2243

Epoch [1/5],                Loss: 0.3253
Epoch [2/5],                Loss: 0.2242
Epoch [3/5],                Loss: 0.2936
Epoch [4/5],                Loss: 0.2388
Epoch [5/5],                Loss: 0.1457
```

Com reset de parâmetros:

[30]:
```
model = OneHotMLP(vocab_size)
train_first_loss_reset(model, best_LR)
train_first_loss_reset(model, best_LR)
```

```
Loss before training: 0.6957

Epoch [1/5],                Loss: 0.4929
Epoch [2/5],                Loss: 0.3588
Epoch [3/5],                Loss: 0.2829
Epoch [4/5],                Loss: 0.2523
Epoch [5/5],                Loss: 0.2483

Loss before training: 0.6972

Epoch [1/5],                Loss: 0.4644
Epoch [2/5],                Loss: 0.3141
Epoch [3/5],                Loss: 0.3423
Epoch [4/5],                Loss: 0.3514
Epoch [5/5],                Loss: 0.3239
```

V.3.a) Repita o exercício V.1.a) porém agora utilizando a equação acima. M - número de amostras
N - número de classes

loss = - 1/(M*N) sumM (sumN (yij*log(y^ij)))

Podemos supor 2 classes (positiva e negativa, e portanto y^ij = 50%)

daí log(y^ij) = log(0.5) = -0.69314.

Com duas classes:

sumN(yij*log(y^ij)) = 2*(yij*(-0.69314)) = -1.38628*yij

loss = -1/(M*N)* sumM(-1.38628*yij)

Se temos duas classes, podemos assumir que metade são da classe 0 e metade da classe 1, e portanto

sumM(yij) = M/2

daí a perda seria dada por

loss = -1/(M2)(M/2)*-1.38628 = 1.38628/2 = 0.69314.

V.3.b) Modifique a camada de saída da rede para 2 logitos e utilize a função Softmax para converter os logitos em probabilidades. Repita o exercício V.1.b)

[31]:
```
class OneHotMLP_2logits(nn.Module):
    def __init__(self, vocab_size):
        super(OneHotMLP_2logits, self).__init__()
        self.fc1 = nn.Linear(vocab_size+1, 200)
        self.fc2 = nn.Linear(200, 2)
        self.relu = nn.ReLU()
        self.softmax = nn.Softmax(dim=1)

    def forward(self, x):
        o = self.fc1(x.float())
        o = self.relu(o)
        o = self.fc2(o)
        return self.softmax(o)
```

[32]:
```
import torch.nn.functional as F

new_loader = DataLoader(train_data, batch_size=128, shuffle=train_shuffle)
model = OneHotMLP_2logits(vocab_size).to(device)

input, target = next(iter(new_loader))
probs_2logits = model(input)

# Calculo numérico da perda
log_probs = F.log_softmax(probs_2logits, dim=1)
log_probs_correct_class = torch.gather(log_probs, 1, target.unsqueeze(1)).
 ↪squeeze(1)
loss = -log_probs_correct_class.mean()
print(loss)
```

```
tensor(0.6941, device='cuda:0', grad_fn=<NegBackward0>)
```

V.3.c) Utilize agora a função nn.CrossEntropyLoss para calcular a Loss e verifique se os resultados são os mesmos que anteriormente.

[33]:
```
loss_fn = nn.CrossEntropyLoss()

loss = loss_fn(probs_2logits.squeeze(), target)
print(loss)
```

```
tensor(0.6941, device='cuda:0', grad_fn=<NllLossBackward0>)
```

Notamos que o valor foi o mesmo que o obtido acima.

V.3.d) Modifique as seções V e VI para que o notebook funcione com a saída da rede com 2 logitos. Há necessidade de alterar o laço de treinamento e o laço de cálculo da acurácia.

[34]:
```
# Treinamento e inferência multi-classe

def train_two_logits(model, lr):

  model = model.to(device)
  reset_weights(model)
  # Define loss and optimizer
  criterion = nn.CrossEntropyLoss()

  optimizer = optim.SGD(model.parameters(), lr)

  # Training loop
  num_epochs = 5

  for epoch in range(num_epochs):

      model.train()

      for inputs, labels in train_loader:

          if not preload_to_gpu:
            inputs = inputs.to(device)
            labels = labels.to(device)

          # Forward pass
          outputs = model(inputs)
          loss = criterion(outputs.squeeze(), labels)

          # Backward and optimize
          optimizer.zero_grad()
          loss.backward()
          optimizer.step()

      print(f'Epoch [{epoch+1}/{num_epochs}], \
              Loss: {loss.item():.4f}')
  print()

def eval_two_logits(model):
    model.eval()

    with torch.no_grad():
        correct = 0
```

```
        total = 0
        for inputs, labels in test_loader:
            inputs = inputs.to(device)
            labels = labels.to(device)
            outputs = model(inputs)
            _, predicted = torch.max(outputs, 1)
            total += labels.size(0)
            correct += (predicted == labels).sum().item()

        acc = 100* correct/total
        print(f'Test Accuracy: {acc}%')
    return acc


model = OneHotMLP_2logits(vocab_size)
train_two_logits(model, best_LR)
eval_two_logits(model)
```

```
Epoch [1/5],                Loss: 0.5940
Epoch [2/5],                Loss: 0.5067
Epoch [3/5],                Loss: 0.4641
Epoch [4/5],                Loss: 0.4820
Epoch [5/5],                Loss: 0.4484

Test Accuracy: 86.74%
```

[34]:
```
86.74
```

Seção VI

VI.1.a) Calcule o número de amostras que está sendo considerado na seção de avaliação.

[35]:
```
print(len(test_data))
```

```
25000
```

VI.1.b) Explique o que faz os comandos model.eval()e with torch.no_grad(). O comando model.eval() informa para o Pytorch que estamos em modo de inferência, o que faz com que algumas camadas dos modelos (como camadas de dropout) sejam desabilitadas.

O loop **with torch.no_grad()** informa o Pytorch para não calcular gradientes relacionados a um tensor. Assim, loops onde o gradiente precisa ser preservado utilizam essa configuração.

VI.1.c) Existe uma forma mais simples de calcular a classe predita na linha 11, sem a necessidade de usar a função torch.sigmoid? Torch.sigmoid() é uma função de ativação, para transformar uma entrada numérica em um número entre zero e um. Uma maneira muito simples de fazer a mesma coisa é dividir a entrada pelo valor máximo da entrada observada, além de, claro, utilizar outras funções de ativação alternativas (ReLU, etc).

VI.2.a) Utilizando a resposta do exercício V.1.a, que é a Loss teórica de um modelo aleatório de 2 classes, qual é o valor da perplexidade?

[36]:
```
torch.exp(torch.tensor(-0.69314))
```

[36]:
```
tensor(0.5000)
```

A perplexidade neste caso nos retorna a probabilidade de distribuição das classes de 50%.

VI.2.b) E se o modelo agora fosse para classificar a amostra em N classes, qual seria o valor da perplexidade para o caso aleatório? Para N classes, a perplexidade seria dada por 1/N.

VI.2.c) Qual é o valor da perplexidade quando o modelo acerta todas as classes com 100% de probabilidade? Quando um modelo acerta 100% das previsões, a perplexidade é 1.

VI.3.a) Modifique o código da seção VI - Avaliação, para que além de calcular a acurácia, calcule também a perplexidade. lembrar que PPL = torch.exp(CE). Assim, será necessário calcular a entropia cruzada, como feito no laço de treinamento.

[37]:
```
def eval_with_perplexity(model):
    model.eval()

    criterion = nn.CrossEntropyLoss()
    #total_loss = 0
    #total_labels = 0
    perplexity = 0

    with torch.no_grad():
        correct = 0
        total = 0
        for inputs, labels in test_loader:
            inputs = inputs.to(device)
            labels = labels.to(device)
            outputs = model(inputs)

            loss = criterion(outputs, labels)
            perplexity = torch.exp(loss)

            _, predicted = torch.max(outputs, 1)
            total += labels.size(0)
            correct += (predicted == labels).sum().item()

        acc = 100* correct/total
        print(f'Test Accuracy: {acc}% \
                Test Perplexity: {perplexity}')
    return acc

eval_with_perplexity(model)
```

```
Test Accuracy: 86.74%                    Test Perplexity: 1.5994813442230225
```

[37]:
```
86.74
```

VI.4.a) Modifique o laço de treinamento para incorporar também o cálculo da avaliação ao final de cada época. Aproveite para reportar também a perplexidade, tanto do treinamento como da avaliação (observe que será mais fácil de interpretar). Essa é a forma usual de se fazer o treinamento, monitorando se o modelo não entra em overfitting.

[38]:
```
def train_and_eval(model, lr, epochs):

  model = model.to(device)
  reset_weights(model)
  # Define loss and optimizer
  criterion = nn.CrossEntropyLoss()

  optimizer = optim.SGD(model.parameters(), lr)

  perplexity = 0
  for epoch in range(epochs):

      model.train()

      for inputs, labels in train_loader:

          if not preload_to_gpu:
            inputs = inputs.to(device)
            labels = labels.to(device)

          # Forward pass
          outputs = model(inputs)
          loss = criterion(outputs.squeeze(), labels)
          perplexity = torch.exp(loss)

          # Backward and optimize
          optimizer.zero_grad()
          loss.backward()
          optimizer.step()

      eval_with_perplexity(model)
      model.train()

      print(f'Epoch [{epoch+1}/{epochs}], \
              Loss: {loss.item():.4f}, \
              Train Perplexity: {perplexity}')
  print()
```

```
model = OneHotMLP_2logits(vocab_size)
train_and_eval(model, best_LR, 5)
```

```
Test Accuracy: 79.372%                Test Perplexity: 1.8890479803085327
Epoch [1/5],              Loss: 0.6000,               Train Perplexity:
1.822061538696289
Test Accuracy: 83.416%                Test Perplexity: 1.7140659093856812
Epoch [2/5],              Loss: 0.5073,               Train Perplexity:
1.6608058214187622
Test Accuracy: 85.052%                Test Perplexity: 1.6764986515045166
Epoch [3/5],              Loss: 0.4443,               Train Perplexity:
1.559381365776062
Test Accuracy: 86.024%                Test Perplexity: 1.583828091621399
Epoch [4/5],              Loss: 0.4751,               Train Perplexity:
1.6081184148788452
Test Accuracy: 86.616%                Test Perplexity: 1.6186288595199585
Epoch [5/5],              Loss: 0.4688,               Train Perplexity:
1.5980067253112793
```

Por fim, como o dataset tem muitas amostras, ele é demorado de entrar em overfitting. Para ficar mais evidente, diminua novamente o número de amostras do dataset de treino de 25 mil para 1 mil amostras e aumente o número de épocas para ilustrar o caso do overfitting, em que a perplexidade de treinamento continua caindo, porém a perplexidade no conjunto de teste começa a aumentar.

[39]:
```
batch_size = 128

train_data_short = IMDBDataset('train', vocab, samples = 1000)
test_data_short = IMDBDataset('test', vocab, samples = 1000)

train_loader = DataLoader(train_data_short, batch_size=batch_size,␣
 ↪shuffle=train_shuffle)
test_loader = DataLoader(test_data_short, batch_size=batch_size, shuffle=False)

model = OneHotMLP_2logits(vocab_size)
train_and_eval(model, best_LR, 100)
```

```
Test Accuracy: 100.0%                Test Perplexity: 1.4652374982833862
Epoch [1/100],              Loss: 0.3981,               Train Perplexity:
1.4890598058700562
Test Accuracy: 100.0%                Test Perplexity: 1.402090311050415
Epoch [2/100],              Loss: 0.3379,               Train Perplexity:
1.4019744396209717
Test Accuracy: 100.0%                Test Perplexity: 1.3873093128204346
Epoch [3/100],              Loss: 0.3279,               Train Perplexity:
1.3881028890609741
Test Accuracy: 100.0%                Test Perplexity: 1.3811591863632202
```

```
Epoch [4/100],              Loss: 0.3222,              Train Perplexity:
1.3801277875900269
Test Accuracy: 100.0%              Test Perplexity: 1.3778650760650635
Epoch [5/100],              Loss: 0.3193,              Train Perplexity:
1.376153588294983
Test Accuracy: 100.0%              Test Perplexity: 1.3758258819580078
Epoch [6/100],              Loss: 0.3194,              Train Perplexity:
1.376289963722229
Test Accuracy: 100.0%              Test Perplexity: 1.3744561672210693
Epoch [7/100],              Loss: 0.3184,              Train Perplexity:
1.3749326467514038
Test Accuracy: 100.0%              Test Perplexity: 1.373476505279541
Epoch [8/100],              Loss: 0.3167,              Train Perplexity:
1.3725703954696655
Test Accuracy: 100.0%              Test Perplexity: 1.372735619544983
Epoch [9/100],              Loss: 0.3178,              Train Perplexity:
1.374079704284668
Test Accuracy: 100.0%              Test Perplexity: 1.3721671104431152
Epoch [10/100],              Loss: 0.3151,              Train Perplexity:
1.370390772819519
Test Accuracy: 100.0%              Test Perplexity: 1.3717094659805298
Epoch [11/100],              Loss: 0.3163,              Train Perplexity:
1.3721094131469727
Test Accuracy: 100.0%              Test Perplexity: 1.371337890625
Epoch [12/100],              Loss: 0.3155,              Train Perplexity:
1.37095308303833
Test Accuracy: 100.0%              Test Perplexity: 1.3710299730300903
Epoch [13/100],              Loss: 0.3152,              Train Perplexity:
1.3705111742019653
Test Accuracy: 100.0%              Test Perplexity: 1.3707679510116577
Epoch [14/100],              Loss: 0.3165,              Train Perplexity:
1.372287631034851
Test Accuracy: 100.0%              Test Perplexity: 1.3705463409423828
Epoch [15/100],              Loss: 0.3147,              Train Perplexity:
1.3699136972427368
Test Accuracy: 100.0%              Test Perplexity: 1.3703547716140747
Epoch [16/100],              Loss: 0.3148,              Train Perplexity:
1.3700511455535889
Test Accuracy: 100.0%              Test Perplexity: 1.37018620967865
Epoch [17/100],              Loss: 0.3158,              Train Perplexity:
1.371317744255066
Test Accuracy: 100.0%              Test Perplexity: 1.3700395822525024
Epoch [18/100],              Loss: 0.3147,              Train Perplexity:
1.3699020147323608
Test Accuracy: 100.0%              Test Perplexity: 1.3699101209640503
Epoch [19/100],              Loss: 0.3144,              Train Perplexity:
1.3694963455200195
Test Accuracy: 100.0%              Test Perplexity: 1.3697941303253174
```

```
Epoch [20/100],              Loss: 0.3145,              Train Perplexity:
1.3696213960647583
Test Accuracy: 100.0%              Test Perplexity: 1.3696900606155396
Epoch [21/100],              Loss: 0.3147,              Train Perplexity:
1.3698198795318604
Test Accuracy: 100.0%              Test Perplexity: 1.3695961236953735
Epoch [22/100],              Loss: 0.3146,              Train Perplexity:
1.3697214126586914
Test Accuracy: 100.0%              Test Perplexity: 1.3695107698440552
Epoch [23/100],              Loss: 0.3147,              Train Perplexity:
1.3699082136154175
Test Accuracy: 100.0%              Test Perplexity: 1.3694332838058472
Epoch [24/100],              Loss: 0.3147,              Train Perplexity:
1.3698039054870605
Test Accuracy: 100.0%              Test Perplexity: 1.3693631887435913
Epoch [25/100],              Loss: 0.3140,              Train Perplexity:
1.368842363357544
Test Accuracy: 100.0%              Test Perplexity: 1.3692984580993652
Epoch [26/100],              Loss: 0.3144,              Train Perplexity:
1.3694206476211548
Test Accuracy: 100.0%              Test Perplexity: 1.3692387342453003
Epoch [27/100],              Loss: 0.3146,              Train Perplexity:
1.3697483539581299
Test Accuracy: 100.0%              Test Perplexity: 1.3691834211349487
Epoch [28/100],              Loss: 0.3147,              Train Perplexity:
1.3698594570159912
Test Accuracy: 100.0%              Test Perplexity: 1.3691322803497314
Epoch [29/100],              Loss: 0.3146,              Train Perplexity:
1.369748592376709
Test Accuracy: 100.0%              Test Perplexity: 1.3690849542617798
Epoch [30/100],              Loss: 0.3146,              Train Perplexity:
1.369724988937378
Test Accuracy: 100.0%              Test Perplexity: 1.3690409660339355
Epoch [31/100],              Loss: 0.3139,              Train Perplexity:
1.3687975406646729
Test Accuracy: 100.0%              Test Perplexity: 1.368999719619751
Epoch [32/100],              Loss: 0.3142,              Train Perplexity:
1.3691222667694092
Test Accuracy: 100.0%              Test Perplexity: 1.368961215019226
Epoch [33/100],              Loss: 0.3141,              Train Perplexity:
1.3689675331115723
Test Accuracy: 100.0%              Test Perplexity: 1.3689253330230713
Epoch [34/100],              Loss: 0.3143,              Train Perplexity:
1.3693097829818726
Test Accuracy: 100.0%              Test Perplexity: 1.368891716003418
Epoch [35/100],              Loss: 0.3137,              Train Perplexity:
1.368466854095459
Test Accuracy: 100.0%              Test Perplexity: 1.368859887123108
```

```
Epoch [36/100],              Loss: 0.3139,              Train Perplexity:
1.368798017501831
Test Accuracy: 100.0%              Test Perplexity: 1.3688302040100098
Epoch [37/100],              Loss: 0.3138,              Train Perplexity:
1.3685476779937744
Test Accuracy: 100.0%              Test Perplexity: 1.3688018321990967
Epoch [38/100],              Loss: 0.3140,              Train Perplexity:
1.3688825368881226
Test Accuracy: 100.0%              Test Perplexity: 1.3687752485275269
Epoch [39/100],              Loss: 0.3136,              Train Perplexity:
1.3684091567993164
Test Accuracy: 100.0%              Test Perplexity: 1.3687498569488525
Epoch [40/100],              Loss: 0.3138,              Train Perplexity:
1.3686186075210571
Test Accuracy: 100.0%              Test Perplexity: 1.3687258958816528
Epoch [41/100],              Loss: 0.3139,              Train Perplexity:
1.3687593936920166
Test Accuracy: 100.0%              Test Perplexity: 1.368703007698059
Epoch [42/100],              Loss: 0.3142,              Train Perplexity:
1.3691896200180054
Test Accuracy: 100.0%              Test Perplexity: 1.3686814308166504
Epoch [43/100],              Loss: 0.3137,              Train Perplexity:
1.3684498071670532
Test Accuracy: 100.0%              Test Perplexity: 1.3686609268188477
Epoch [44/100],              Loss: 0.3137,              Train Perplexity:
1.3684937953948975
Test Accuracy: 100.0%              Test Perplexity: 1.3686413764953613
Epoch [45/100],              Loss: 0.3136,              Train Perplexity:
1.368397831916809
Test Accuracy: 100.0%              Test Perplexity: 1.3686225414276123
Epoch [46/100],              Loss: 0.3138,              Train Perplexity:
1.3685566186904907
Test Accuracy: 100.0%              Test Perplexity: 1.3686045408248901
Epoch [47/100],              Loss: 0.3143,              Train Perplexity:
1.3692359924316406
Test Accuracy: 100.0%              Test Perplexity: 1.3685874938964844
Epoch [48/100],              Loss: 0.3137,              Train Perplexity:
1.368489146232605
Test Accuracy: 100.0%              Test Perplexity: 1.368571162223816
Epoch [49/100],              Loss: 0.3139,              Train Perplexity:
1.3687890768051147
Test Accuracy: 100.0%              Test Perplexity: 1.3685554265975952
Epoch [50/100],              Loss: 0.3138,              Train Perplexity:
1.3686046600341797
Test Accuracy: 100.0%              Test Perplexity: 1.3685404062271118
Epoch [51/100],              Loss: 0.3139,              Train Perplexity:
1.368720293045044
Test Accuracy: 100.0%              Test Perplexity: 1.3685258626937866
```

```
Epoch [52/100],              Loss: 0.3142,              Train Perplexity:
1.369149923324585
Test Accuracy: 100.0%              Test Perplexity: 1.3685119152069092
Epoch [53/100],              Loss: 0.3136,              Train Perplexity:
1.368369698524475
Test Accuracy: 100.0%              Test Perplexity: 1.368498682975769
Epoch [54/100],              Loss: 0.3136,              Train Perplexity:
1.3682812452316284
Test Accuracy: 100.0%              Test Perplexity: 1.3684860467910767
Epoch [55/100],              Loss: 0.3137,              Train Perplexity:
1.368517518043518
Test Accuracy: 100.0%              Test Perplexity: 1.3684738874435425
Epoch [56/100],              Loss: 0.3135,              Train Perplexity:
1.3682323694229126
Test Accuracy: 100.0%              Test Perplexity: 1.3684619665145874
Epoch [57/100],              Loss: 0.3137,              Train Perplexity:
1.3685381412506104
Test Accuracy: 100.0%              Test Perplexity: 1.368450403213501
Epoch [58/100],              Loss: 0.3142,              Train Perplexity:
1.369145154953003
Test Accuracy: 100.0%              Test Perplexity: 1.3684395551681519
Epoch [59/100],              Loss: 0.3134,              Train Perplexity:
1.3680731058120728
Test Accuracy: 100.0%              Test Perplexity: 1.3684290647506714
Epoch [60/100],              Loss: 0.3136,              Train Perplexity:
1.368316411972046
Test Accuracy: 100.0%              Test Perplexity: 1.3684189319610596
Epoch [61/100],              Loss: 0.3136,              Train Perplexity:
1.368345022201538
Test Accuracy: 100.0%              Test Perplexity: 1.3684089183807373
Epoch [62/100],              Loss: 0.3139,              Train Perplexity:
1.368705153465271
Test Accuracy: 100.0%              Test Perplexity: 1.3683993816375732
Epoch [63/100],              Loss: 0.3140,              Train Perplexity:
1.3688586950302124
Test Accuracy: 100.0%              Test Perplexity: 1.3683900833129883
Epoch [64/100],              Loss: 0.3143,              Train Perplexity:
1.3693068027496338
Test Accuracy: 100.0%              Test Perplexity: 1.368381142616272
Epoch [65/100],              Loss: 0.3135,              Train Perplexity:
1.368220567703247
Test Accuracy: 100.0%              Test Perplexity: 1.3683725595474243
Epoch [66/100],              Loss: 0.3136,              Train Perplexity:
1.3683326244354248
Test Accuracy: 100.0%              Test Perplexity: 1.3683642148971558
Epoch [67/100],              Loss: 0.3135,              Train Perplexity:
1.3681540489196777
Test Accuracy: 100.0%              Test Perplexity: 1.3683559894561768
```

```
Epoch [68/100],              Loss: 0.3139,              Train Perplexity:
1.3686999082565308
Test Accuracy: 100.0%              Test Perplexity: 1.368348240852356
Epoch [69/100],              Loss: 0.3135,              Train Perplexity:
1.368147611618042
Test Accuracy: 100.0%              Test Perplexity: 1.3683404922485352
Epoch [70/100],              Loss: 0.3139,              Train Perplexity:
1.3687909841537476
Test Accuracy: 100.0%              Test Perplexity: 1.3683332204818726
Epoch [71/100],              Loss: 0.3139,              Train Perplexity:
1.3687148094177246
Test Accuracy: 100.0%              Test Perplexity: 1.36832594871521
Epoch [72/100],              Loss: 0.3136,              Train Perplexity:
1.3683280944824219
Test Accuracy: 100.0%              Test Perplexity: 1.3683189153671265
Epoch [73/100],              Loss: 0.3139,              Train Perplexity:
1.3687971830368042
Test Accuracy: 100.0%              Test Perplexity: 1.368312120437622
Epoch [74/100],              Loss: 0.3139,              Train Perplexity:
1.368705153465271
Test Accuracy: 100.0%              Test Perplexity: 1.3683055639266968
Epoch [75/100],              Loss: 0.3135,              Train Perplexity:
1.3682001829147339
Test Accuracy: 100.0%              Test Perplexity: 1.3682992458343506
Epoch [76/100],              Loss: 0.3136,              Train Perplexity:
1.3683652877807617
Test Accuracy: 100.0%              Test Perplexity: 1.3682929277420044
Epoch [77/100],              Loss: 0.3135,              Train Perplexity:
1.3682271242141724
Test Accuracy: 100.0%              Test Perplexity: 1.3682869672775269
Epoch [78/100],              Loss: 0.3135,              Train Perplexity:
1.3681442737579346
Test Accuracy: 100.0%              Test Perplexity: 1.3682812452316284
Epoch [79/100],              Loss: 0.3135,              Train Perplexity:
1.3682386875152588
Test Accuracy: 100.0%              Test Perplexity: 1.3682754039764404
Epoch [80/100],              Loss: 0.3134,              Train Perplexity:
1.3681339025497437
Test Accuracy: 100.0%              Test Perplexity: 1.368269920349121
Epoch [81/100],              Loss: 0.3138,              Train Perplexity:
1.3685861825942993
Test Accuracy: 100.0%              Test Perplexity: 1.3682644367218018
Epoch [82/100],              Loss: 0.3135,              Train Perplexity:
1.3681398630142212
Test Accuracy: 100.0%              Test Perplexity: 1.3682591915130615
Epoch [83/100],              Loss: 0.3135,              Train Perplexity:
1.368175745010376
Test Accuracy: 100.0%              Test Perplexity: 1.3682540655136108
```

```
Epoch [84/100],              Loss: 0.3135,              Train Perplexity:
1.368200421333313
Test Accuracy: 100.0%              Test Perplexity: 1.3682489395141602
Epoch [85/100],              Loss: 0.3137,              Train Perplexity:
1.3684122562408447
Test Accuracy: 100.0%              Test Perplexity: 1.3682440519332886
Epoch [86/100],              Loss: 0.3140,              Train Perplexity:
1.3688278198242188
Test Accuracy: 100.0%              Test Perplexity: 1.3682392835617065
Epoch [87/100],              Loss: 0.3135,              Train Perplexity:
1.3682599067687988
Test Accuracy: 100.0%              Test Perplexity: 1.3682345151901245
Epoch [88/100],              Loss: 0.3135,              Train Perplexity:
1.368152141571045
Test Accuracy: 100.0%              Test Perplexity: 1.3682301044464111
Epoch [89/100],              Loss: 0.3134,              Train Perplexity:
1.3681014776229858
Test Accuracy: 100.0%              Test Perplexity: 1.3682255744934082
Epoch [90/100],              Loss: 0.3136,              Train Perplexity:
1.3683029413223267
Test Accuracy: 100.0%              Test Perplexity: 1.3682212829589844
Epoch [91/100],              Loss: 0.3134,              Train Perplexity:
1.3680342435836792
Test Accuracy: 100.0%              Test Perplexity: 1.36821711063385
Epoch [92/100],              Loss: 0.3135,              Train Perplexity:
1.3682141304016113
Test Accuracy: 100.0%              Test Perplexity: 1.3682128190994263
Epoch [93/100],              Loss: 0.3138,              Train Perplexity:
1.368651270866394
Test Accuracy: 100.0%              Test Perplexity: 1.368208885192871
Epoch [94/100],              Loss: 0.3135,              Train Perplexity:
1.3681857585906982
Test Accuracy: 100.0%              Test Perplexity: 1.3682047128677368
Epoch [95/100],              Loss: 0.3139,              Train Perplexity:
1.3687580823898315
Test Accuracy: 100.0%              Test Perplexity: 1.3682007789611816
Epoch [96/100],              Loss: 0.3135,              Train Perplexity:
1.368249535560608
Test Accuracy: 100.0%              Test Perplexity: 1.368196964263916
Epoch [97/100],              Loss: 0.3138,              Train Perplexity:
1.3686814308166504
Test Accuracy: 100.0%              Test Perplexity: 1.36819326877594
Epoch [98/100],              Loss: 0.3138,              Train Perplexity:
1.3686493635177612
Test Accuracy: 100.0%              Test Perplexity: 1.3681894540786743
Epoch [99/100],              Loss: 0.3136,              Train Perplexity:
1.3683782815933228
Test Accuracy: 100.0%              Test Perplexity: 1.3681858777999878
```

```
Epoch [100/100],                Loss: 0.3142,                Train Perplexity:
1.3692086935043335
```